

Análisis Inteligente y Segmentación para la Agroindustria de la Región de Coquimbo

Entregable 2, Proyecto de Big Data para la Toma de Decisiones, UCN,
primer semestre 2026

Integrantes:	Maximiliano Berrios. Sebastián Castillo. Lisette Mathieu. Alejandro Núñez. Gabriel Tenorio. Matheus Villavicencio
Grupo:	9, AgroTech.
Curso:	Big Data para la Toma de Decisiones.
Profesor:	Vanessa Duarte Correa.
Fecha:	Viernes 5 de junio, 2026.

Índice

1. Resumen Ejecutivo	2
2. Análisis Descriptivo	3
2.1 Matrices de correlaciones de spearman por producto	3
2.2 Evolución mensual de precios por producto	4
2.3 Distribución de Precios Agrícolas	4
2.4 Entorno Macroeconómico vs Precio Agrícola Mediano	5
3. Segmentación mediante Clustering	6
3.1 Técnica de segmentación y justificación metodológica	6
3.2 Perfilamiento de clústeres y estrategias comerciales	8
4. Definición Predictiva y Meta-Datos	10
5. Anexo: Tabla de Aporte Individual	11

1. Resumen Ejecutivo

Este scraper se enfoca en analizar la evolución de los precios de productos agrícolas de alta demanda en los hogares chilenos, específicamente papa, tomate, limón, naranja, uva y palta. La variación de los precios de estos productos puede afectar directamente el presupuesto familiar y la planificación de compra de los consumidores.

Para comprender mejor los factores que influyen en estas variaciones, se incorporaron variables externas relacionadas con la producción y comercialización agrícola, tales como el precio del petróleo, asociado a los costos de transporte y distribución; variables climáticas como temperatura, humedad, precipitaciones y radiación ultravioleta (UV), que influyen en el desarrollo y rendimiento de los cultivos; y el valor del dólar estadounidense, que puede afectar el costo de insumos agrícolas importados y otros gastos asociados al sector. El análisis se encuentra limitado a la Región de Coquimbo y considera información correspondiente a los años 2024, 2025 y 2026.

El análisis descriptivo muestra que la uva y la papa presentan la mayor variabilidad relativa en sus precios, con coeficientes de variación de 60,6% y 60,2%, respectivamente, evidenciando una mayor sensibilidad a factores como la estacionalidad, las condiciones climáticas y las fluctuaciones de la oferta y demanda. Por el contrario, la palta presenta el comportamiento más estable, con un coeficiente de variación de 28,5%, seguida por la naranja con un 43,6%. Asimismo, se observa que las ferias libres presentan una dispersión de precios considerablemente mayor que los supermercados, lo que refleja diferencias en los mecanismos de formación de precios y en la respuesta a las condiciones del mercado.

Los resultados del análisis multivariado indican que las variables climáticas, especialmente la humedad, las precipitaciones y la radiación UV, son las que presentan una mayor contribución en la diferenciación de patrones de precios entre productos. En contraste, variables macroeconómicas como la tasa de cambio del dólar y el precio del petróleo muestran una influencia significativamente menor dentro de los modelos analizados.


Para asegurar que los resultados fueran confiables, se realizó una limpieza de los datos eliminando registros duplicados y corrigiendo inconsistencias encontradas durante el procesamiento. Además, se completaron algunos valores faltantes utilizando la información disponible, evitando así la pérdida de datos importantes para el análisis. Los precios más altos o más bajos se mantuvieron en la base de datos, ya que reflejan situaciones reales del mercado y permiten representar de mejor manera el comportamiento de los productos agrícolas. Gracias a este proceso, se obtuvo un conjunto de datos más ordenado y consistente para realizar los análisis y desarrollar los modelos predictivos.

Además, para mejorar el conjunto de datos y fortalecer la capacidad de análisis, se incorporaron nuevas variables derivadas. Entre ellas destacan `precio_normalizado`, que permite trabajar con precios estandarizados; `variación`, que mide los cambios porcentuales en los precios a lo largo del tiempo; y las variables temporales `dia_año` y `semana_año`, que facilitan la identificación de patrones asociados a fechas específicas. También se creó `estacionalidad_index`, que permite representar los efectos de las distintas épocas del año sobre los precios agrícolas. Finalmente, se integró la variable `tasa_cambio`, incorporando el comportamiento del dólar como un factor económico potencialmente relacionado con las variaciones de precios observadas en el mercado.

2. Análisis Descriptivo


2.1 Matrices de correlaciones de spearman por producto

El análisis de correlación muestra que los productos agrícolas no responden de la misma manera a las variables estudiadas. En el caso de la palta y el limón, se observa una mayor relación con factores estacionales, lo que indica que la época del año influye de forma importante en el comportamiento de sus precios. Esto coincide con los resultados obtenidos en otros análisis, donde variables climáticas como las precipitaciones y la humedad mostraron una influencia relevante sobre estos productos. Por otro lado, variables macroeconómicas como el dólar y el precio del petróleo presentan correlaciones bajas en la mayoría de los casos, lo que sugiere que su efecto sobre los precios finales es limitado en comparación con otros factores. Asimismo, productos como la uva, la naranja y la papa muestran relaciones menos claras con las variables analizadas, a pesar de presentar una alta variabilidad en sus precios; por ejemplo, la uva y la papa registraron coeficientes de variación cercanos al 60%, siendo los productos más volátiles del conjunto de datos. Estos resultados indican que existen otros factores que podrían estar influyendo en las fluctuaciones de precios, tales como la oferta disponible, la calidad del producto, las estrategias comerciales o las condiciones específicas del mercado.



2.2 Evolución mensual de precios por producto

El gráfico de evolución mensual de precios muestra diferencias importantes en el comportamiento de los productos agrícolas a lo largo del año. La palta mantiene los precios más altos durante todo el período analizado, alcanzando valores cercanos a \$5.100 por kilogramo durante el primer semestre y descendiendo gradualmente hasta aproximadamente \$3.900 hacia noviembre, para luego presentar una leve recuperación en diciembre. La uva se posiciona como el segundo producto de mayor valor, mostrando una caída significativa en junio, cuando su precio promedio disminuye hasta cerca de \$1.850, seguida de una recuperación que la mantiene sobre los \$3.000 durante el segundo semestre. Por otro lado, la naranja, el limón, el tomate y la papa presentan precios considerablemente más estables y bajos, fluctuando principalmente entre los \$900 y \$1.800. Además, las bandas de dispersión indican que la palta y la uva presentan una mayor variabilidad en sus precios durante el año, mientras que la papa y el tomate muestran un comportamiento más estable.




Fuente: Elaboración propia

2.3 Distribución de Precios Agrícolas

El análisis descriptivo de los precios agrícolas evidencia diferencias importantes entre los productos, canales de comercialización y períodos del año. La palta presenta los precios más elevados y una alta dispersión, seguida por la uva, mientras que la papa, el limón y el tomate muestran valores promedio considerablemente más bajos. Respecto a los canales de venta, las ferias libres registran una mayor variabilidad de precios ($CV = 88\%$) en comparación con los supermercados ($CV = 57\%$), lo que indica una mayor sensibilidad a cambios en la oferta y la demanda. A nivel temporal, se observa que la media mensual es sistemáticamente superior a la mediana, especialmente durante el primer semestre, lo que sugiere la presencia de valores extremos que elevan el promedio de los precios. Finalmente, las distribuciones por comuna muestran comportamientos muy similares, con precios promedio cercanos a \$1.800 en Ovalle, La Serena y Coquimbo, lo que indica que las diferencias geográficas tienen un impacto menor en comparación con factores como el tipo de producto o el canal de comercialización. En conjunto, estos resultados sugieren que la variación de precios está principalmente asociada a las características propias de cada producto y a las condiciones de venta más que a la ubicación geográfica dentro de la Región de Coquimbo.


Distribución de Precios Agrícolas — Análisis Descriptivo



Fuente: Elaboración propia

2.4 Entorno Macroeconómico vs Precio Agrícola Mediano

Se observa que el precio agrícola presenta una tendencia descendente durante gran parte del año, pasando de aproximadamente \$1.580 en enero a un mínimo cercano a \$1.000 en agosto, para luego recuperarse durante el último trimestre y cerrar el año sobre los \$1.500. En contraste, tanto el dólar como el precio del petróleo muestran fluctuaciones relativamente moderadas y no siguen un patrón similar al de los precios agrícolas. Por ejemplo, en septiembre el petróleo alcanza uno de sus valores más altos mientras que el precio agrícola se mantiene en niveles intermedios, y durante diciembre los precios agrícolas aumentan significativamente a pesar de que el petróleo disminuye. De manera similar, el tipo de cambio permanece relativamente estable durante el año, sin evidenciar una relación directa con las variaciones observadas en los precios agrícolas.



Fuente: Elaboración propia

3. Segmentación mediante Clustering

3.1 Técnica de segmentación y justificación metodológica

Para la estructuración y descubrimiento de patrones dentro de la base de datos de 6.655 registros limpios alojados en la colección `processed_data` de MongoDB, se seleccionó el algoritmo de particionamiento K-Means estudiado en el curso. La pertinencia de este estimador no supervisado para el proyecto AgroTech en el análisis de variables agrícolas, climáticas y macroeconómicas, se fundamenta en los siguientes cinco argumentos técnicos y de control de gestión, basados en el comportamiento y diseño del pipeline:

- a) **Rendimiento y eficiencia en entornos contenerizados como Docker:** Dado que se trabaja con una base de datos con una colección con 10.761 diccionarios brutos y otra con 7.021 registros limpios, el rendimiento es fundamental debido a la naturaleza no relacional del almacenamiento inicial. Como ha sido estudiado en el curso, se seleccionó el algoritmo K-Means porque procesa datos de forma lineal y rápida a través de optimizaciones iterativas, computando eficientemente las distancias y asignaciones de clústeres de manera independiente del volumen de datos que se encuentren en la colección depurada.

La selección de K-Means también se fundamenta en que en esta asignatura se utiliza Docker Compose para levantar todo el pipeline en un servidor local. Si se hubiera escogido otro método analítico, como el clustering jerárquico, además de implicar la integración de nuevos paradigmas tecnológicos, las estaciones de trabajo del equipo habrían sufrido restricciones severas de memoria RAM debido al peso de las matrices de distancia y los cálculos matemáticos correspondientes al EDA. Por el contrario, K-Means determinó las agrupaciones en solo unos segundos, permitiendo procesar de manera efectiva y eficiente los productos agrícolas objetivo, incluso para los cultivos con mayor densidad de registros dentro de la arquitectura local.

- b) **Estandarización y sensibilidad diferencial de variables explicativas:** Los datos extraídos y almacenados en la colección `raw_data` poseen una naturaleza altamente heterogénea, combinando escalas de temperatura ambiente, porcentajes de humedad, valores de divisas y precios en moneda local. El pipeline de preprocesamiento convirtió estos documentos brutos en una estructura cuantitativa homogénea apta para K-Means, el cual opera agrupando observaciones según su proximidad en un espacio multidimensional basado en la distancia euclidiana.

Para que el algoritmo pudiera computar estas distancias de forma justa, primero se normalizaron las variables continuas con `StandardScaler` (fijando una media 0 y una varianza 1) y se codificaron los atributos cualitativos (calidad y `lugar_monitoreo`) mediante `OneHotEncoder`. Si no se hubiese realizado esta estandarización, las variables con rangos numéricos amplios habrían distorsionado el modelo por completo. No obstante, es imperativo destacar que la normalización no dota a todas las variables de la misma relevancia en la separación final. El análisis de los clústeres demostró que las variables climáticas locales específicamente la **humedad, las precipitaciones y la radiación UV** explican la mayor parte de la varianza y la segregación de los grupos, mientras que los indicadores del macroentorno económico aportaron una fuerza de atracción significativamente menor en la conformación de los perfiles.

- c) **Superación de sesgo de escala nominal mediante análisis dirigido:** Uno de los logros metodológicos más destacados del equipo fue transicionar desde un enfoque global hacia un clustering dirigido por producto agrícola, lo cual permitió reconocer dinámicas comerciales específicas para cada cultivo. Anteriormente se había intentado un análisis unificado que procesaba todos los productos de forma simultánea; sin embargo, este fue descartado porque no generaba una segmentación de utilidad para la toma de decisiones respecto a los períodos óptimos de manejo técnico y comercial.

En las fases previas para la preparación del entregable, al ejecutar un K-Means único mezclando todas las categorías sin distinción, el modelo evidenció una clara ineficiencia

diagnóstica. Al coexistir un producto de alto valor unitario como la palta con otros de consumo masivo y menor precio nominal, la varianza del modelo se concentraba casi exclusivamente en la brecha de valor entre los productos. Como consecuencia, el K-Means original tendía a homogeneizar la realidad, integrando observaciones dispersas en una macrocategoría difusa. Al reestructurar el pipeline para aislar los registros de cada producto antes del entrenamiento, se eliminó el ruido generado por las diferencias de precios interproducto, permitiendo al algoritmo identificar las verdaderas tendencias internas de cada cultivo.

- d) **Evaluación del valor óptimo de particionamiento y comportamiento estacional:** En lugar de asumir un número arbitrario o automático de agrupaciones, el equipo evaluó rigurosamente la estructura de los datos utilizando la métrica de **Silhouette Score** para determinar el valor óptimo de K para cada escenario. Este enfoque metodológico evidenció que cada producto responde a dinámicas de mercado y ciclos productivos completamente distintos, resultando en una estructura de segmentación diferenciada por cultivo: **Limón (K=5), Naranja (K=5), Palta (K=4), Papa (K=6), Tomate (K=2) y Uva (K=2)**

Esta sensibilidad del algoritmo, guiada por la optimización matemática del Silhouette Score y aplicada de forma independiente, es la que permite capturar anomalías estacionales y ventanas de oportunidad críticas. En un modelo unificado global, las fluctuaciones de precios inducidas por la estacionalidad climática o los peaks de cosecha locales se habrían diluido e invisibilizado dentro del promedio general, privando al sistema de la capacidad de informar sobre los momentos de comercialización más estratégicos y rentables para los productores de la región.

- e) **Capacidad de afrontar el impacto logístico y caracterización del entorno:** Una de las finalidades del proyecto AgroTech es transicionar desde la analítica descriptiva hacia un marco que apoye la toma de decisiones y mitigue riesgos para los agricultores de la Región de Coquimbo. A través de la inspección de los centroides de los clústeres generados, K-Means actúa como una herramienta de diagnóstico que permite evaluar qué factores gobiernan la vulnerabilidad de cada cultivo.

Al analizar la composición de los grupos, el modelo determinó, por ejemplo, que variables macroeconómicas como la tasa_cambio y el precio_petroleo_contexto poseen contribuciones marginales en la separación de los datos (explicando típicamente entre un 0% y un 5% de la varianza). Esto demuestra cuantitativamente que el riesgo crítico para el productor no se encuentra indexado directamente a las macrotendencias de la divisa o los combustibles globales, sino a factores contextuales internos y a la saturación de los canales de distribución locales según el comportamiento del clima. Este hallazgo valida la necesidad de un control de gestión basado en evidencia empírica, permitiendo a los agricultores planificar sus estrategias de distribución y desvío de stocks basándose en perfiles de datos rigurosos en lugar de actuar por simple intuición o costumbres históricas.

3.2 Perfilamiento de clústeres y estrategias comerciales

Como fue mencionado anteriormente, los clústeres fueron perfilados para cada producto agrícola para que hubiese un análisis más detallado y unas estrategias particulares para cada cosecha. Esto se debe a que cada fruta y verdura analizada posee distintas características, períodos de cosecha y costos asociados. En la siguiente tabla se sintetizan algunos datos relevantes respecto al modelo K-Means para cada producto agrícola:

Producto agrícola	Registros para entrenamiento	Cantidad de clústeres	Precio de kilo de referencia base	Comportamientos detectados
Limón	1.403	5	\$1.225	Presión bajista con alta oferta (ferias), comportamiento regular de mercado y alta cotización (supermercados).
Naranja	1.154	5	\$1.512	Comportamiento regular de mercado, presión bajista con alta oferta y alta cotización.
Palta	1.112	4	\$4.505	Comportamiento regular de mercado, presión bajista y alta cotización.
Papa	1.577	6	\$980	Comportamiento regular de mercado, presión bajista con alta oferta y alta cotización.
Tomate	998	2	\$1.208	Comportamiento regular de mercado y presión bajista estacional (enero).
Uva	411	2	\$2.495	Comportamiento regular de mercado con estabilidad de precios (sensible a humedad).
Total	Total de clústeres: 25			

A continuación se presenta un clúster y perfil comercial para cada uno de los seis productos agrícolas analizados en este proyecto, conectando las variables del entorno con decisiones de mercado y demostrando que la decisión de perfilar cada producto por separado contribuye a un análisis más focalizado y provechoso.

- a) **Mercado del limón - Conveniencia comercial en marzo (Clúster n°3):** es el grupo más grande del limón con 685 registros (48,8% del total). Posee un precio promedio de \$1.396, siendo algo mayor que la referencia base de \$1.225. Comercializa mayormente en ferias libres (63,8%), con ventas comerciales que ocurren principalmente a fines de verano (mes de marzo), bajo temperaturas de 14,8°C, humedad del 78,5% y un precio promedio del barril de petróleo de \$62.732.

El algoritmo lo clasifica como una "Ventana Alta/Premium". El análisis de datos demuestra que a finales del verano el limón logra una alta cotización en ferias libres antes de llegar el otoño. La estrategia sería consolidar y ofrecer limones en marzo, aprovechando que el costo del combustible no es el más alto del año.

- b) **Mercado de naranja - Estabilidad del mercado sin condiciones ventajosas (Clúster n°2):** este clúster domina el estudio de la naranja con 715 registros (62% de la muestra). El precio promedio se encuentra en \$1.453, cerca del valor base de referencia de \$1.512. Octubre es el mes predominante (primavera), con temperaturas templadas de 12,6°C, alta humedad (79,7%) y un costo logístico elevado con el barril de petróleo a \$65,382. El 65,2% de las ventas son realizadas en ferias libres y el producto es mayoritariamente de calidad "Primera" (69,5%).

Este clúster se etiqueta como "Comportamiento Regular de Mercado". En octubre hay un flujo constante y predecible de naranjas a la venta, pero el valor del flete debería ser alto porque el precio del barril de petróleo es costoso. La sugerencia para la toma de decisiones sería estandarizar costos de transporte y diseñar rutas logísticas más eficientes hacia las ferias de La Serena y Ovalle para proteger el flujo masivo de naranjas que es lo que sostiene la estabilidad de los ingresos.

- c) **Mercado de palta - Estabilidad del mercado sin condiciones ventajosas (Clúster n°2):** este clúster presenta el mayor peso con 564 registros (50,7% del total de la palta). Registra un precio promedio de \$4.249, inferior a la base de \$4.505. Su mes predominante es noviembre, con un clima de 12,5°C y 79,4% de humedad. La distribución se inclina un 62,6% hacia las ferias libres y un 37,4% a supermercados, habiendo una calidad "Primera" en el 58,9% del total de registros.

Al igual que el clúster de la naranja descrito anteriormente, el de la palta queda con "Comportamiento Regular de Mercado". En noviembre fluye con fuerza el volumen de palta regional hacia los canales tradicionales. La estrategia operativa sería asegurar el volumen constante de palta en las ferias libres durante la primavera, ya que, aunque el precio baja un poco respecto a otros meses, la alta representatividad de este clúster asegura la rotación rápida del inventario sin alto riesgo de mermas por almacenamiento prolongado.

- d) **Mercado de papa - Distribución invernal (Clúster n°1):** dicho clúster representa la mitad del negocio analizado con 829 registros (52,6% del total de la muestra). El precio está levemente por debajo de la base, promediando \$935 (la base es de \$980). El mes clave de este perfil es julio (pleno invierno), con temperaturas bajas de 12,6°C y alta humedad (79,7%). Las ferias libres concentran el 64,1% de la oferta y la calidad predominante es "Primera" (70%).

Este clúster está definido con un "Comportamiento Regular de Mercado". Julio representa el centro del invierno y en él hay una estabilidad de la papa regional, habiendo un mercado que dispone producto de buena calidad a un precio cercano a la referencia base. La decisión estratégica aquí debería centrarse en la continuidad de suministro hacia las ferias, aprovechando que hay una demanda estable que podría deberse al aumento de su consumo durante los meses fríos.

- e) **Mercado de tomate - Flujo tradicional en invierno (Clúster n°0):** dicho clúster es el grupo mayoritario con 464 registros (46,5% del total). Muestra un precio promedio de \$1.272, superando la referencia base de \$1.208. Ocurre principalmente en el mes de julio, registrando un entorno con 12,7°C de temperatura, 79,6% de humedad y un precio de barril de petróleo de \$65.358. Las ferias libres controlan el 66,6% del canal de venta y la calidad es mayormente "Primera" (69%).

El sistema perfila este clúster con "Comportamiento Regular de Mercado" pero con muy buena tracción de precios. En julio (invierno), el tomate de primera logra mantener un buen precio de venta en las ferias libres de Coquimbo y La Serena. La recomendación sería aprovechar la ventana invernal estable para comercializar la producción hacia las ferias, absorbiendo el costo del petróleo alto mediante un precio superior que el mercado está dispuesto a pagar por un producto de buena calidad en dicha época.

- f) **Mercado de uva - cosecha abundante en marzo (Clúster n°2):** este grupo concentra 174 registros (42,3% del dataset limpio de uva). Tiene un precio promedio equilibrado de \$2.462, muy parecido al valor base de \$2,495. Su período comercial se concentra en el mes de marzo (fines de verano), marcando temperaturas de 14,0°C, humedad de 79,1% y un precio de barril de petróleo de \$64.106. El 69,5% de los productos se comercializa en ferias libres y se destaca el estándar más alto de calidad con un 86,8% de "Primera".

Este clúster es catalogado con "Comportamiento Regular de Mercado". Marzo tiene un

flujo masivo y real de la vendimia y cosecha de mesa regional. Casi el 87% de la uva de este bloque es de primera calidad, por lo que se podría plantear una estrategia de negociación basada en el estándar del producto: asegurar la colocación en ferias mayoristas y locales de forma masiva, usando la excelente calidad como argumento de venta para mantener el precio estable.

4. Definición Predictiva y Meta-Datos

La variable dependiente seleccionada para la siguiente etapa del proyecto corresponde al Precio (CLP) de los productos agrícolas. Esta variable fue elegida porque representa el principal foco de análisis de la investigación y permite evaluar cómo diferentes factores influyen en las variaciones de precios observadas en el mercado agrícola de la Región de Coquimbo. El objetivo será utilizar la información histórica disponible para estimar el valor futuro de los productos a partir de características como el tipo de producto, la comuna, el canal de comercialización, variables climáticas y el período del año. La factibilidad de construir un modelo predictivo es alta debido a la calidad y cantidad de información disponible. El conjunto de datos reúne miles de registros distribuidos entre las comunas de La Serena, Coquimbo y Ovalle, con más de 2.000 observaciones en cada una de ellas. Esta cobertura permite analizar el comportamiento de los precios desde distintas perspectivas y proporciona una base sólida para identificar tendencias y relaciones entre las variables.

Durante el análisis exploratorio se observaron diferencias importantes entre los productos estudiados. La uva presentó la mayor variabilidad relativa de precios, con un coeficiente de variación de 60,6%, seguida muy de cerca por la papa con un 60,2%. En contraste, la palta mostró el comportamiento más estable, con una variabilidad relativa de 28,5%. Estos resultados indican que el tipo de producto constituye una de las variables más relevantes para explicar las fluctuaciones de precios observadas en el mercado agrícola. Asimismo, se identificaron diferencias significativas entre los canales de comercialización. Las ferias libres presentaron una dispersión de precios considerablemente mayor que los supermercados, alcanzando un coeficiente de variación de 88,0% frente al 57,5% observado en supermercados. Esto evidencia un comportamiento más variable y sensible a las condiciones del mercado, mientras que los supermercados muestran una estructura de precios más estable y consistente. En consecuencia, el canal de comercialización representa una variable con alto potencial explicativo para los modelos predictivos.

Otro hallazgo relevante fue la presencia de patrones temporales y estacionales. La evolución mensual de los precios muestra períodos donde determinados productos aumentan o disminuyen su valor de manera consistente, sugiriendo una relación directa con los ciclos productivos agrícolas y las condiciones climáticas. En este contexto, variables como el mes del año, la humedad, las precipitaciones y la radiación ultravioleta adquieren especial importancia, ya que los análisis de segmentación evidenciaron que son algunos de los factores con mayor capacidad para diferenciar comportamientos de precios entre distintos productos. Por otra parte, las diferencias observadas entre comunas fueron relativamente pequeñas en comparación con las diferencias registradas entre productos y canales de comercialización. Esto sugiere que el producto comercializado y el canal de venta poseen un mayor poder explicativo sobre el precio que la ubicación geográfica por sí sola. De igual manera, variables macroeconómicas como la tasa de cambio del dólar y el precio del petróleo mostraron una contribución menor dentro de los análisis realizados, aunque se mantuvieron en el conjunto de datos por su posible influencia indirecta sobre los costos de producción y distribución.

Finalmente, el proceso de limpieza y validación permitió eliminar registros duplicados, corregir inconsistencias y completar valores faltantes utilizando la información disponible, manteniendo los valores extremos que representan situaciones reales del mercado. Gracias a ello, el conjunto de datos refleja de manera más precisa el comportamiento de los precios agrícolas. Considerando la cantidad de observaciones disponibles, la presencia de patrones identificables y la influencia demostrada de variables relacionadas con el producto, el canal de comercialización, la estacionalidad y las condiciones climáticas, se concluye que existen condiciones favorables para desarrollar un modelo predictivo capaz de estimar los precios agrícolas con un nivel adecuado de precisión en la siguiente etapa del proyecto.

5. Anexo: Tabla de Aporte Individual

Estudiante	Responsabilidad técnica específica	Rama de Trabajo	N° Commits
Maximiliano Berrios	Responsable de la redacción del informe formal en PDF y la consolidación de la estructura del repositorio según requerimientos.	Documentación y Calidad	2
Sebastian Castillo	Responsable de la implementación del algoritmo de Clustering, Validación técnica (Codo/Silueta) e interpretación de segmentos.	Modelado No Supervisado	3
Lisette Mathieu	Responsable del análisis multivariado, detección de anomalías y visualización de correlaciones.	Análisis Descriptivo (EDA)	1
Alejandro Nuñez	Responsable de la configuración del clúster en MongoDB Atlas, manejo de secretos (.env) y conexión segura del pipeline. Responsable de la creación del segundo contenedor (Docker) para la limpieza, transformación y carga de datos en la colección processed_data.	- Gestión de Infraestructura Cloud - Ingeniería de Datos y Pipeline	7
Gabriel Tenorio	Responsable de la implementación del algoritmo de Clustering, Validación técnica (Codo/Silueta) e interpretación de segmentos.	Modelado No Supervisado	3
Mathieus Villavicencio	Responsable del análisis multivariado, detección de anomalías y visualización de correlaciones.	Análisis Descriptivo (EDA)	7